

Problem 1

(a)

1. 策略採用高斯分布: $a \sim N(\mu, \sigma^2)$, 以便同時預測 μ 和 σ ; 網路輸出 $\log \sigma \rightarrow$ 取指數後保證 $\sigma > 0$, 並可將 $\log \sigma$ 截在 $[-20, 2]$ 避免數值過大或過小
2. 建立分布: $\text{dist} = N(\mu, \sigma)$, 用可微採樣 $z = \text{dist.vsample}()$, 等價於 $z = \mu + \sigma \epsilon$ ($\epsilon \sim N(0, I)$), 可對 μ, σ 反向傳播
3. 重力作經 $a = \tanh(z)$ 且落在 $(-1, 1)$, 非線性變換會改變寬度, 需做校正:

$$\log \pi(a) = \log \pi(z) - \sum \log |1 - \tanh^2(z_i)|$$

(b)

1. 過度估計偏差: 單一 Q 網路在做最大值回歸時容易高估真實值
 取最小值糾正: 同時維護兩個相反的 Q 網路 Q_1, Q_2 , 更新時對下一狀態 Q 值取最小
 $\min(Q_1, Q_2)$ 以降低過度估計

2.

$$a' \sim \pi(\cdot | s_{t+1}), y_t = r_t + \gamma(1 - d_t)(\min(Q_1(s_{t+1}, a'), Q_2(s_{t+1}, a')) - 2 \log \pi(a' | s_{t+1}))$$


$$L_Q(Q_i) = E_{(s_t, a_t, r_t, s_{t+1}) \sim D} [(Q_{\theta_i}(s_t, a_t) - y_t)^2]$$

(c)

我們要最小化 $J(\alpha) = E_{s, a \sim \pi} [-2(\log \pi(a|s)) + \text{tray}]$ 以及優化 $\log \alpha$

$\Rightarrow$ 將溫度參數寫作 $\alpha = e^l$, 其中 $l =$

(d)



Return 曲線：

0-5 000 步：初始 return 約 -1 000，偶有跌至 -1 700，隨隨機探索逐步回升。

5 000-20 000 步：return 從 -500 上升至約 -130。

20 000–100 000 步：return 穩定在 -100 左右，少量波動；至 100 000 步，策略能穩定獲得 ≥ -110 。

Critic 損失 Q-loss：

初期因隨機動作帶來大幅 TD 誤差，峰值可達 3 000 以上。

訓練後半段緩慢下降，在 100 000 步左右穩定在 500 以下。

V-loss：

初始峰值約 50，經過 $\sim 20\,000$ 步後下降並在 10 以下收斂，波動減小。

α -loss：

熵溫度 α 的損失 α -loss 初始非常高 ($\approx +500$)，表示策略熵遠高於目標熵。

在前 20 000 步內快速衰減至接近 0，說明自適應機制成功將策略熵調向目標值 (-1)。

Result：

最後 20 個 episode 的平均 return： -107.3 ± 3.8







達到 -130 所需步數：約 15 000

達到 -130 所需 episode：約 75

參數：

Lr = $3e-4$, discount-factor = 0.99, tau = $5e-3$, batch_size = 128, initial-random-steps = 1000, memory-size = 100000, num-steps = 100000, policy-update-freq = 2, seed = 77.

(e)



Return：

0–80 k 步：回報在 $[-500, 0]$ 之間波動。

80 k–200 k 步：迅速上升，至 ≈ 2000 。

200 k–1 000 k 步：繼續緩慢提升，最終穩定在 5000~6000 區間。

Q-loss／V-loss：

前期因隨機探索誤差極大（可達 10^8 、 10^6 ），快速衰減後在低於 $10^3/10^2$ 的水準振盪。

α -loss：

開始時有大幅波動（ ± 50 ），在約 50 k 步後收斂至 0，表明策略熵已接近目標值。

Result:

最後 20 個 episode 平均 return： 5584 ± 120

達到 3000 回報門檻步數：約 250 000 步

達到 5000 回報門檻步數：約 700 000 步

無法達到作業要求 total-reward 在 7000~12000，和同學討論後認為是 HalfCheetah 改版後造成分數上限被降低了。

參數：

Lr = $3e-4$, discount-factor = 0.99, tau = $5e-3$, batch_size = 256, initial-random-steps = 10000, memory-size = 1000000, num-steps = 1000000, policy-update-freq = 1, seed = 77.