

(1)

直覺來看DRG的公式描述的是兩點

- 1° 從策略輸出到行為的影響，即 $\nabla \theta \pi \theta$
- 2° Q 的梯度。先計算當前動作對 Q 的影響 $(\nabla_{\theta} Q \pi \theta(s, a))$ ，再評估 action 的好壞

1° 2° 結合起來就能知道微小改變策略參數如何影響最終累積報酬

DRG 與隨機策略梯度的差異在於後者會先從策略中抽取動作，再利用 $\nabla \log \pi \theta(a|s)$ 與 Q 值的乘積來更新參數；前者直接對確定性策略微分，不需要對連續動作空間進行積分或抽樣，從而降低梯度估計的方差。

(2)

off-policy learning 可以使用由不同行為策略所產生的數據。學習過程不需要數據必須是從當前正在改進的策略中產生，而是可以使用過去或其他來源的經驗與資料學習。

以自動駕馬車為例，其可以利用大量由人類駕馬車員產生的數據來學習如何駕駛，即使最終目標並不完全模仿人類。這種利用既有數據進行學習就是 off-policy learning。

(3)

我覺得有三點

(a) 直接輸出連續動作，簡化了計算流程

(b) 降低梯度估計的方差

(c) 高效利用連續性訊息